UNIVERSIDADE FEDERAL DE SANTA MARIA
CENTRO DE CIÊNCIAS RURAIS
DEPARTAMENTO DE FITOTECNIA
PROGRAMA DE PÓS-GRADUAÇÃO EM AGRONOMIA

CRISTHIAN MILBRADT BABESKI

QUESTÕES - EXAME DE QUALIFICAÇÃO DE DOUTORADO

Respostas às questões do(a) examinador(a):
Prof. Ivan Ricardo Carvalho - Membro da Banca Examinadora
(Coorientador)

Santa Maria, RS
2026

Sumário

QUESTÃO 1 - AMBIENTÔMICA: CONCEITO, APLICABILIDADES E EXPECTATIVAS 3
1.1 CONCEITO E FUNDAMENTOS 3
1.2 APLICABILIDADES 4
1.3 EXPECTATIVAS, LIMITAÇÕES E PERSPECTIVAS 5
1.4 A AMBIENTÔMICA NESTE PROJETO DE TESE 5
QUESTÃO 2 - FENÔMICA: CONCEITO, APLICABILIDADES E EXPECTATIVAS 7
2.1 CONCEITO E FUNDAMENTOS 7
2.2 APLICABILIDADES 8
2.3 EXPECTATIVAS, LIMITAÇÕES E PERSPECTIVAS 8
2.4 A FENÔMICA NESTE PROJETO DE TESE 9
QUESTÃO 3 - MODELOS COM APLICABILIDADE EM AMBIENTÔMICA E FENÔMICA 10
3.1 ESTRATÉGIA: UM CATÁLOGO ORGANIZADO POR FAMÍLIA E UMA AVALIAÇÃO COMUM 10
3.2 CATÁLOGO DE MODELOS E APLICABILIDADES 10
3.3 EXEMPLO EM R E RELATÓRIO R MARKDOWN 12
3.4 COMO ESCOLHER O MODELO NOS DADOS REAIS 14
REFERÊNCIAS BIBLIOGRÁFICAS 15
APÊNDICE A - SCRIPT EM R (QUESTÃO 3) 20

QUESTÃO 1 - AMBIENTÔMICA: CONCEITO, APLICABILIDADES E EXPECTATIVAS

Enunciado: Discorra sobre Ambientômica, aplicabilidades e expectativas.

1.1 CONCEITO E FUNDAMENTOS

A ambientômica (*enviromics*) é uma análise, em larga escala, usada para caracterizar ambiente, inciciando com a ambientipagem (*envirotyping*), que consiste em determinar e medir os fatores ambientais que afetam o crescimento e a produtividade das culturas (XU, 2016). Quando essa caracterização é feita em alto desempenho, com muitas variáveis, em várias escalas de tempo e espaço e integrada a dados genotípicos e fenotípicos, tem-se a ambientômica, em analogia direta com a genômica e a fenômica. O objeto de estudo é o ambientoma, o conjunto dos fatores ambientais que atuam sobre a planta (RESENDE et al., 2021; COSTA-NETO et al., 2023).

O ambiente, nesse sentido, é o conjunto dos fatores analisados em que os organismos vivem (COSTA-NETO et al., 2023). Porém, nos experimentos, ele costuma ser reduzido a um rótulo de local, safra e manejo. O rótulo informa onde e quando o ensaio foi conduzido, mas não explica por que os genótipos se comportaram de forma diferente. A ambientômica troca o rótulo por covariáveis medidas (temperatura, radiação, precipitação, déficit hídrico, solo, manejo), que podem ser recalculadas por estádio fenológico e usadas como preditoras nos modelos.

A base conceitual é da ecofisiologia com a lei da tolerância de Shelford, a lei do mínimo de Liebig e a plasticidade fenotípica, segundo as quais a resposta da planta a cada fator tem limites, ótimos e um fator limitante em cada momento (COSTA-NETO et al., 2023). Em termos estatísticos, o fenótipo é função do genótipo, do ambiente e da interação entre eles ($P = G + E + G \times E$). A genômica descreve o G, a fenômica mede o P, e a ambientômica descreve o E, o que permite explicar a interação G×E em vez de apenas detectá-la.

Operacionalmente, o fluxo tem quatro etapas: coleta (estações, satélites e bases gradeadas como NASA POWER, MODIS e Landsat, além de solo e manejo), controle de qualidade (dados faltantes, valores atípicos e resoluções diferentes), processamento (cálculo de variáveis com sentido ecofisiológico, como balanço hídrico e acúmulo térmico por estádio) e modelagem (COSTA-NETO et al., 2023). Há ferramentas em R que integram ambientômica e genética quantitativa, como o pacote EnvRtype (COSTA-NETO et al., 2021b).

O termo aparece também em outro sentido, o da ecovigilância baseada em ômicas, que usa genômica, transcriptômica, proteômica e metabolômica para avaliar função, saúde e resiliência de ecossistemas (BEALE et al., 2022). As duas leituras partem da mesma ideia, a de que o ambiente deve ser medido de forma sistemática. Nesta resposta uso principalmente a primeira, voltada à interação G×E, e trato a segunda como aplicação.

1.2 APLICABILIDADES

As aplicações vão do melhoramento ao manejo e ao monitoramento territorial, o seguinte quadro 1 resume as principais funções:

Quadro 1. Principais aplicabilidades da ambientômica.

Aplicação	O que se faz	Referências
Explicar G×E	Relacionar a interação a covariáveis (déficit hídrico, temperatura) por regressão fatorial ou modelos fatoriais analíticos, em vez de só quantificá-la.	COSTA-NETO et al., 2023; ARAÚJO et al., 2025; SOUSA et al., 2026
Zoneamento e mega-ambientes	Agrupar locais por similaridade ambiental e delimitar zonas em que a interação G×E é pequena.	COSTA-NETO et al., 2023
Recomendação de cultivares	Indicar a cultivar para o ambiente-alvo, inclusive onde não há ensaio, com mapas em SIG.	COSTA-NETO et al., 2023; RESENDE et al., 2025
Normas de reação e predição genômica	Usar covariáveis ambientais e marcadores no mesmo modelo, aumentando a acurácia de predição entre ambientes.	JARQUÍN et al., 2014; COSTA-NETO; FRITSCHE-NETO; CROSSA, 2021a
Ecofisiologia e manejo	Definir época de semeadura, janela de cultivo e ideótipos por ambiente a partir de limites e ótimos de cada fator.	COSTA-NETO et al., 2023
Ecovigilância e planejamento territorial	Monitorar ecossistemas e áreas urbanas, identificar vulnerabilidade climática e apoiar políticas públicas.	BEALE et al., 2022;

Fonte: elaborada pelo autor com base nas referências citadas. SIG: Sistema de Informação Geográfica

Diversos estudo vem integrando ambietômica; em ensaios de rede com soja foi analisada com modelos fatoriais analíticos e ambientipagem para otimizar a seleção de genótipos (ARAÚJO et al., 2025). Em trigo tropical, a interação G×E foi modelada com covariáveis ambientais para recomendar genótipos (SOUSA et al., 2026). Em milho, a modelagem G×E baseada em SIG com marcadores ambientais permite mapear o desempenho de híbridos no espaço (RESENDE et al., 2025). Quando a ambientômica entra na predição genômica, as covariáveis passam a compor o modelo e não só a descrevê-lo (JARQUÍN et al., 2014; COSTA-NETO; FRITSCHE-NETO; CROSSA, 2021a).

Fora do melhoramento, a mesma lógica de medir o ambiente de forma integrada sustenta o monitoramento de áreas rurais e urbanas: dados de satélite, drones e plataformas climáticas apontam áreas de estresse térmico, risco de enchente ou degradação, e subsidiam corredores ecológicos e infraestrutura verde. Na ecovigilância, os dados ômicos ampliam o diagnóstico para contaminantes emergentes e respostas biológicas (BEALE et al., 2022).

1.3 EXPECTATIVAS, LIMITAÇÕES E PERSPECTIVAS

As expectativas para a área são de maior resolução e de maior integração, resultando em dados climáticos e covariáveis no nível de pixel da parcela, em vez de médias de município ou de grade (COSTA-NETO et al., 2023). Em integração, a literatura aponta modelos multimodais que liguem dados moleculares e celulares a informações de satélite, o que ajudaria espécies com poucos recursos genômicos, e o desenho de ideótipos orientados por dados, combinando genômica, ambientômica e modelos de simulação de cultura (COSTA-NETO et al., 2023). O melhoramento baseado em predição já integra as covariáveis ambientais como parte do processo para avaliação de fenótipos de alto rendimento (FRITSCHE-NETO et al., 2025).

A caracterização do padrão ambiental em redes de ensaios é apontada como o principal gargalo da área. Dados faltantes, valores atípicos e resoluções ruins exigem controle de qualidade, com imputação por krigagem ou Random Forest, e efeitos ambientais costumam ser não lineares, o que pede transformação antes da modelagem. Os modelos de simulação de cultura capturam poucas interações, e os modelos estatísticos dependem do número e da localização dos ensaios (COSTA-NETO et al., 2023). Essas informações também pesam para armazenar e processar grandes volumes de dados e a governança desses dados (MANSOOR et al., 2025).

Uma cautela de interpretação são as covariáveis de estação ou de grade não substituem solo, manejo e microclima da parcela, e a associação entre uma covariável e a interação G×E não prova causa. A ambientômica explica parte da interação, não toda, e suas conclusões só valem para a faixa ambiental amostrada.

1.4 A AMBIENTÔMICA NESTE PROJETO DE TESE

Neste projeto a ambientômica entra por duas vias, sendo a que primeira é a caracterização das safras com covariáveis de temperatura, radiação e precipitação obtidas pelo NASA POWER, que permite relacionar o desempenho e a estabilidade dos genótipos às causas ambientais, por regressão fatorial. A segunda é a doença no Artigo 3, umidade e chuva definem

a favorabilidade ao patógeno e são as covariáveis naturais para explicar a severidade de doenças foliares, podendo entrar no mesmo modelo que os índices RGB.

A limitação principal é que os experimentos foram conduzidos em um único local e em poucas safras. As covariáveis explicam a variação entre safras, mas não autorizam extrapolar para outros ambientes sem validação espacial em novos locais (ROBERTS et al., 2017). O passo seguinte é ampliar a rede de ambientes, o que ao mesmo tempo aumenta a herdabilidade na média e dá poder estatístico para a regressão sobre covariáveis.

QUESTÃO 2 - FENÔMICA: CONCEITO, APLICABILIDADES E EXPECTATIVAS

Enunciado: Discorra sobre Fenômica, aplicabilidades e expectativas.

2.1 CONCEITO E FUNDAMENTOS

Fenômica é a aquisição de dados fenotípicos de alta dimensão em escala de avaliação de plantas de forma a mensurar a influência do ambiente (HOULE; GOVINDARAJU; OMHOLT, 2010). Ela surgiu porque o genoma passou a ser lido em escala industrial enquanto o fenótipo continuou sendo medido de forma lenta, cara e subjetiva, o chamado gargalo da fenotipagem (FURBANK; TESTER, 2011). A fenotipagem de alto rendimento (HTP, do inglês *high-throughput phenotyping*) é o conjunto de plataformas e sensores que gera os dados; a fenômica é a ciência que os integra e interpreta, relacionando genótipo, ambiente e fenótipo em larga escala (ZAVAFER et al., 2023).

As plataformas incluem sensores RGB, multiespectrais, hiperespectrais e térmicos, embarcados em VANT, tratores ou estruturas fixas, ou ainda fotografias de campo, combinados a algoritmos de aprendizado de máquina que extraem os traços (ARAUS; CAIRNS, 2014; MANSOOR et al., 2025). Os traços vão de variáveis simples, como índices de vegetação, cobertura e temperatura de dossel, a fenótipos derivados, como severidade de doença, fenologia e estimativa de produtividade.

O valor de um traço de HTP para o melhoramento depende de três propriedades: repetibilidade, correlação genética com o caráter-alvo e custo por parcela (ARAUS et al., 2018). A resposta correlacionada, $CRy = i \cdot hx \cdot hy \cdot rg \cdot \sigma Py$, formaliza isso (FALCONER; MACKAY, 1996), onde i é a intensidade de seleção, hx e hy são as raízes das herdabilidades do índice e do rendimento, rg é a correlação genética entre eles e σPy é o desvio-padrão fenotípico do rendimento. Um índice de imagem só serve de critério de seleção se for herdável e geneticamente correlacionado com o que se quer melhorar.

Fenômica e ambientômica são camadas complementares do mesmo problema, sendo que a fenômica mede a resposta observável da planta; a ambientômica mede o efeito que a causou, e essa combinação fornece um uma inferência mais completa do desempenho do que ambas isoladas na avaliação de fenotipagem (ZAVAFER et al., 2023; MANSOOR et al., 2025).

2.2 APLICABILIDADES

Quadro 2. Principais aplicabilidades da fenômica.

Aplicação	O que se faz	Referências
Seleção indireta de rendimento	Usar índices RGB ou multiespectrais, medidos em muitas parcelas, como caráter secundário para selecionar o rendimento.	RUTKOSKI et al., 2016; MACHADO E SILVA et al., 2024; ARAUS et al., 2018
Predição genômica com fenotipagem	Somar índices de HTP aos marcadores para aumentar a acurácia da predição e da seleção.	RUTKOSKI et al., 2016; CRAIN et al., 2018
Soja com imagens de VANT	Fenotipar soja com índices de vegetação RGB de drone e estimar parâmetros de rendimento, inclusive sob acamamento.	ALVES et al., 2024; BAI et al., 2022; CHAGAS et al., 2026
Severidade de doenças	Estimar a severidade por imagem, reduzindo a variação entre avaliadores da nota visual.	BOCK; CHIANG; DEL PONTE, 2022
Florestas e monitoramento	Caracterizar produtividade em escala de floresta com aprendizado de máquina; monitorar cobertura vegetal e estresse em áreas urbanas.	BOMBRUN et al., 2020;
Fisiologia vegetal	Medir respostas a estresses em muitas plantas e ao longo do tempo, de forma não destrutiva.	ZAVAFER et al., 2023

Fonte: elaborada pelo autor com base nas referências citadas.

Em trigo, índices de vegetação e temperatura de dossel obtidos por HTP melhoraram a acurácia da seleção das plantas visuais e da seleção genômica para rendimento de grãos (RUTKOSKI et al., 2016), e a combinação de HTP com informação genômica elevou a acurácia de predição e de seleção (CRAIN et al., 2018). Em trigo tropical, índices multiespectrais de VANT foram avaliados para seleção indireta (MACHADO E SILVA et al., 2024). Em soja, índices RGB de drone já são usados em programas de melhoramento (ALVES et al., 2024), e sensores RGB permitiram estimar parâmetros de rendimento mesmo sob acamamento (BAI et al., 2022).

A estimativa visual da severidade de doenças, usada há mais de um século, depende do avaliador, e sua acurácia exige boas práticas de avaliação (BOCK; CHIANG; DEL PONTE, 2022). A imagem substitui a nota subjetiva por uma medida repetível, que pode ser tomada em muitas parcelas e datas, sendo uma ferramento como auxilio de campo de avaliação severidade

2.3 EXPECTATIVAS, LIMITAÇÕES E PERSPECTIVAS

A expectativa central é traduzir fenotipagem em ganho genético: avaliar mais parcelas por unidade de custo e de tempo, com maior precisão, aumenta a intensidade e a acurácia da seleção (ARAUS et al., 2018). A segunda expectativa é a integração: modelos únicos que combinem marcadores, covariáveis ambientais e fenótipos de HTP, em vez de tratá-los como problemas separados (FRITSCHE-NETO et al., 2025). A terceira é o uso de inteligência

artificial para ir da medição do traço à decisão, do índice à recomendação de genótipos (CHAGAS et al., 2026; MANSOOR et al., 2025).

As limitações são de quatro tipos: Primeiro, confundidores: iluminação, altura de voo, fenologia, arquitetura de planta e a presença simultânea de doenças alteram a resposta espectral sem alterar a produtividade, e é isso que o Artigo 3 avalia ao testar alturas de voo. Segundo, o salto de predição para seleção: bom ajuste não garante herdabilidade nem correlação genética (FALCONER; MACKAY, 1996), e a predição precisa ser validada fora da amostra de treino, em novas parcelas, voos, safras e locais (ROBERTS et al., 2017), com atenção à calibração e não só ao R^2 (LIN, 1989; VAN CALSTER et al., 2019). Terceiro, a transferência: um modelo treinado em um ambiente ou conjunto de cultivares tende a perder desempenho em outro. Quarto, dados e infraestrutura: volume, armazenamento, padronização e inferência a partir de parâmetros bem definidos (MANSOOR et al., 2025).

2.4 A FENÔMICA NESTE PROJETO DE TESE

No Artigo 3, a severidade de doenças foliares da soja (mancha-alvo, oídio e mancha olho-de-rã) é estimada por índices RGB extraídos de imagens aéreas de VANT, avaliando o efeito da altura de voo. No Artigo 4, fotografias de folíolos são usadas para predizer o rendimento de grãos: dos índices calculados, a seleção por ReliefF manteve o VARI e o ExGR, e o método final foi o Gradient Boosting, avaliado em um conjunto de construção e em dois conjuntos independentes (cultivares em outro ambiente e linhagens F5).

O desenho com conjuntos independentes é a resposta do projeto à principal limitação da fenômica, a de transformar predição em critério de seleção. O que ainda falta é o teste definitivo, o ganho de seleção realizado: selecionar com o índice, avançar as linhagens e comparar o rendimento medido com o de linhagens não selecionadas (FALCONER; MACKAY, 1996).

QUESTÃO 3 - MODELOS COM APLICABILIDADE EM AMBIENTÔMICA E FENÔMICA

Enunciado: Apresente todos os modelos de seu conhecimento com aplicabilidades em ambientômica e fenômica com script em R e relatório R Markdown.

3.1 ESTRATÉGIA: UM CATÁLOGO ORGANIZADO POR FAMÍLIA E UMA AVALIAÇÃO COMUM

O problema geral é Y = f(ambiente, fenótipo de imagem) + erro. A escolha do modelo depende de duas perguntas: se o objetivo é explicar ou prever (BREIMAN, 2001b), e que estrutura têm os dados, se tabulares com poucas variáveis, se de alta dimensão com forte colinearidade, ou se com medidas repetidas por ambiente. Por isso o catálogo da seção 3.2 está organizado por partes, do mais interpretável ao mais flexível.

Todos os modelos são avaliados da mesma forma: mesma partição treino/teste, padronização calculada apenas no treino, hiperparâmetros escolhidos por validação cruzada e métricas RMSE, MAE e R^2 (CHAI; DRAXLER, 2014; WILLMOTT; MATSUURA, 2005). Modelos baseados em verossimilhança são comparados também por AIC e AICc (AKAIKE, 1974; HURVICH; TSAI, 1989; BURNHAM; ANDERSON, 2002). Quando os dados têm estrutura de blocos, voos ou safras, usa-se validação cruzada em blocos (ROBERTS et al., 2017).

3.2 CATÁLOGO DE MODELOS E APLICABILIDADES

Os quadros 3 e 4 reúnem os modelos utilizados, com a ideia de cada um e o uso em ambientômica (A) e fenômica (F). Os modelos mistos, a regressão fatorial e o AMMI atuam sobre a estrutura de ensaios em vários ambientes; os demais atuam sobre a relação entre preditoras e resposta.

Quadro 3. Modelos lineares, estruturados, robustos, bayesianos, penalizados e aditivos.

Modelo (função em R)	Expressão ou ideia	Aplicabilidade	Referências
Modelo misto REML/BLUP (lme4, nlme)	$Y = X\beta + Zu + \varepsilon$; genótipo, ambiente e G×E como efeitos aleatórios	A: componentes de variância e herdabilidade. F: BLUP do genótipo a partir de medidas repetidas.	CRUZ et al., 2012; COELHO et al., 2021; VOLPATO et al., 2019
Regressão fatorial e norma de reação	Efeito do genótipo regredido sobre covariáveis ou índice ambiental	A: explicar G×E por covariáveis (chuva, temperatura).	FINLAY; WILKINSON, 1963; EBERHART; RUSSELL, 1966; JARQUÍN et al., 2014
AMMI (metan, agricolae)	Efeitos principais aditivos + interação em eixos multiplicativos	A: separar genótipos de adaptação ampla e específica em biplots.	GAUCH, 1992
Regressão linear múltipla (lm)	$\hat{Y} = \beta0 + \Sigma\ \beta iXi$, mínimos quadrados	A: efeito marginal de cada covariável. F: referência mínima que os demais modelos devem superar.	JAMES et al., 2021
Stepwise (step)	Lm com entrada e saída de variáveis por AIC	A: escolher covariáveis relevantes. F: reduzir índices redundantes.	AKAIKE, 1974
Regressão com interação entre bandas (lm)	$\hat{Y} = \beta0 + \beta1R + \beta2G + \beta3B + \beta4RG + \beta5RB + \beta6GB + \beta7RGB$	F: efeito combinado das bandas sem transformá-las em índice.	Sem referência específica
Mínimos quadrados generalizados (nlme::gls)	$\hat{Y} = X\beta + \varepsilon$, $\varepsilon \sim N(0, \Sigma)$	A e F: variância do erro que cresce com a média, ou autocorrelação entre parcelas vizinhas e voos.	PINHEIRO; BATES, 2000
Regressão robusta (MASS::rlm)	Minimiza $\Sigma\ \rho(yi - xi'\beta)$, ρ de Huber	F: fotos com sombra ou flash geram valores atípicos. A: leituras com anomalias de estação.	HUBER, 1964
Regressão bayesiana (arm::bayesglm, brms)	$p(\beta\|y) \propto p(y\|X,\beta)\cdot p(\beta)$	A e F: poucas observações, uso de prior informativo, intervalo de credibilidade na predição.	GELMAN et al., 2008
Ridge (glmnet)	Minimiza $\Sigma(yi - xi'\beta)^2 + \lambda\Sigma\beta j^2$	F: bandas e índices muito correlacionados. A: covariáveis climáticas correlacionadas.	HOERL; KENNARD, 1970
Lasso (glmnet)	Minimiza $\Sigma(yi - xi'\beta)^2 + \lambda\Sigma\|\beta j\|$	A e F: seleção automática de covariáveis ou índices.	TIBSHIRANI, 1996
GAM (mgcv::gam)	$g(E[Y]) = \beta0 + \Sigma\ fj(Xj)$, splines	A: curvas de resposta com ótimos térmicos. F: saturação do índice com a severidade.	HASTIE; TIBSHIRANI, 1986; WOOD, 2017
Regressão não linear (nls)	$\hat{Y} = f(X; \theta) + \varepsilon$, forma paramétrica	A: curvas ecofisiológicas com parâmetros interpretáveis (temperatura ótima). F: curvas de crescimento e senescência.	SEBER; WILD, 1989

Fonte: elaborada pelo autor. A = ambientômica; F = fenômica.

Quadro 4. Modelos de aprendizado de máquina.

Modelo (função em R)	Expressão ou ideia	Aplicabilidade	Referências
K-vizinhos mais próximos (caret::knnreg)	$\hat{Y}(x) = (1/K)\ \Sigma$ yi dos K vizinhos de x	F: similaridade entre fotos e parcelas; sensível a escala e dimensão.	COVER; HART, 1967
Máquina de vetores de suporte (e1071::svm)	Hiperplano de margem máxima, kernel linear ou radial	F: alta dimensão com poucas amostras (hiperespectral). A: classificação de zonas.	CORTES; VAPNIK, 1995
Random Forest (ranger)	$\hat{Y} = (1/B)\ \Sigma$ Tb(x), média de B árvores	A e F: importância de variáveis e robustez a não linearidade. F: índices RGB e severidade (Artigo 3).	BREIMAN, 2001a
XGBoost (xgboost)	$L = \Sigma\ l(yi, \hat{y}i) + \Omega(ft)$, boosting com regularização	A e F: dados tabulares com muitas variáveis (Artigo 3).	CHEN; GUESTRIN, 2016
Gradient Boosting (gbm)	$F_m(x) = F_(m-1)(x) + \gamma m \cdot hm(x)$, árvores sequenciais	F: predição de rendimento por índices do folíolo (Artigo 4).	FRIEDMAN, 2001
Rede neural artificial (nnet)	$\hat{Y} = f(W2 \cdot \sigma(W1X + b1) + b2)$, uma camada oculta	A e F: relações não lineares complexas quando há muitos dados.	RUMELHART; HINTON; WILLIAMS, 1986
Aprendizado profundo (keras)	Várias camadas ocultas; redes convolucionais para imagem	F: imagens diretamente, sem calcular índices. A: séries temporais de satélite. Exige muitos dados.	LECUN; BENGIO; HINTON, 2015

Fonte: elaborada pelo autor. A = ambientômica; F = fenômica.

3.3 EXEMPLO EM R E RELATÓRIO R MARKDOWN

O script e o relatório R Markdown que acompanham esta resposta (Apêndice A e arquivos anexos) simulam um banco com a estrutura dos dados da tese: quatro covariáveis ambientais (temperatura, umidade, precipitação e radiação), as bandas R, G e B e três índices de vegetação (VARI, GLI e NGRDI), e a severidade de doença foliar como resposta, com n = 600. O banco é salvo em Excel. A severidade aumenta com umidade e chuva, tem um ótimo de temperatura com resposta quadrática e reduz o verde da imagem; a banda azul é praticamente ruído, como observado no Artigo 3. Os dados são simulados: servem para demonstrar o funcionamento do código e do raciocínio de escolha, não para estimar o desempenho real.

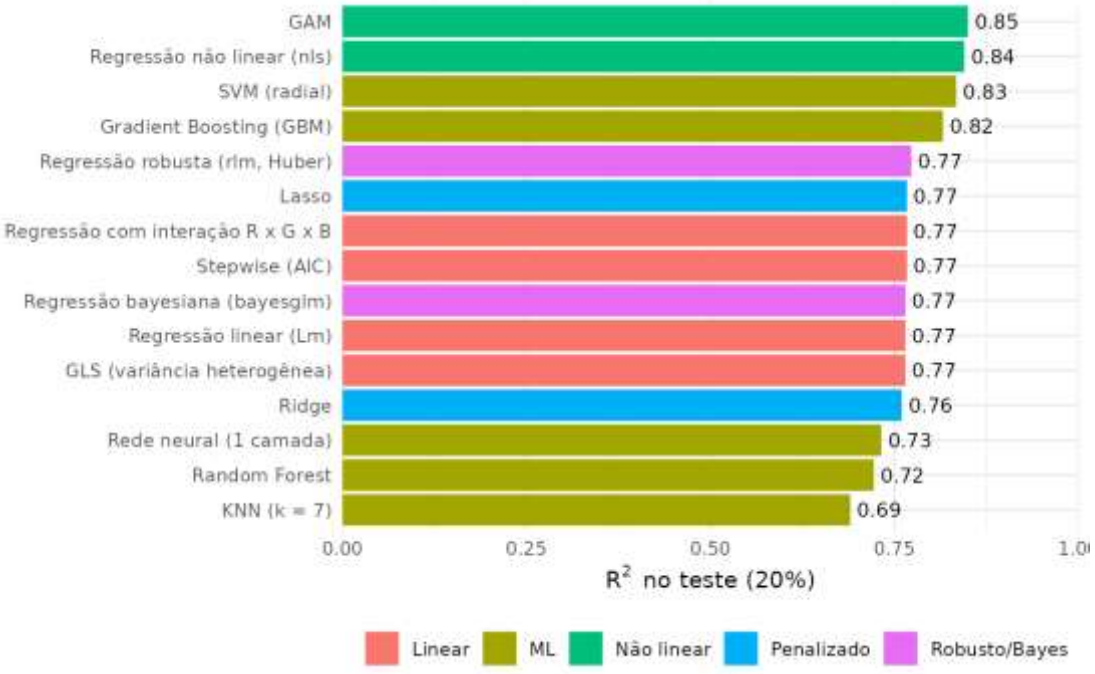
A divisão foi de 80% para treino (480 observações) e 20% para teste (120), com semente fixa. O quadro 5 mostra o desempenho no teste.

Quadro 5. Desempenho dos modelos no conjunto de teste (20%), em ordem de R².

Modelo	Família	RMSE	MAE	R²
GAM	Não linear	4,514	3,657	0,850
Regressão não linear (nls)	Não linear	4,582	3,621	0,845
SVM (radial)	ML	4,745	3,811	0,834
Gradient Boosting (GBM)	ML	4,989	3,998	0,816
Regressão robusta (rlm, Huber)	Robusto/Bayes	5,549	4,577	0,773
Lasso	Penalizado	5,614	4,657	0,767
Regressão com interação R x G x B	Linear	5,615	4,641	0,767
Stepwise (AIC)	Linear	5,619	4,665	0,767
Regressão bayesiana (bayesglm)	Robusto/Bayes	5,643	4,674	0,765
Regressão linear (Lm)	Linear	5,644	4,675	0,765
GLS (variância heterogênea)	Linear	5,644	4,675	0,765
Ridge	Penalizado	5,704	4,735	0,760
Rede neural (1 camada)	ML	6,033	4,943	0,732
Random Forest	ML	6,144	5,013	0,722
KNN (k = 7)	ML	6,482	5,238	0,690

Fonte: dados simulados (script do Apêndice A). RMSE e MAE na mesma unidade da severidade (%).

Figura 1. R² de cada modelo no conjunto de teste (20%).



Fonte: dados simulados (script do Apêndice A).

O GAM ($R^2 = 0,85$) e a regressão não linear (0,845) ficaram na frente porque o dado tem um ótimo térmico em forma de curva, que eles representam diretamente. SVM (0,83) e

Gradient Boosting (0,82) vieram logo atrás. Os modelos lineares, robusto, bayesiano, Lasso e Ridge ficaram praticamente empatados, em torno de 0,77: com 480 observações todos estimam essencialmente a mesma relação linear, e penalização, robustez e prior pouco mudam um banco sem valores atípicos. Rede neural, Random Forest e KNN ficaram atrás (0,73, 0,72 e 0,69), em um banco pequeno e quase aditivo

O quadro 6 compara o mesmo modelo com três conjuntos de preditoras, para separar o que cada camada explica. No modelo linear, o ambiente sozinho chegou a R^2 de 0,667 e a imagem sozinha a 0,495; as duas juntas, a 0,765. A imagem prediz a severidade pela consequência (verde perdido) e o ambiente, pela causa (favorabilidade); juntos se complementam. Na Random Forest o ganho não apareceu (0,726 só com ambiente e 0,722 com as duas), o que lembra que mais variáveis não garantem mais acerto.

Quadro 6. Desempenho no teste por conjunto de preditoras.

Preditoras	Modelo	RMSE	MAE	R^2
Só ambiente	Linear (Lm)	6,723	5,186	0,667
Só imagem RGB	Linear (Lm)	8,273	6,569	0,495
Ambiente + imagem	Linear (Lm)	5,644	4,675	0,765
Só ambiente	Random Forest	6,092	4,761	0,726
Só imagem RGB	Random Forest	8,506	6,702	0,466
Ambiente + imagem	Random Forest	6,144	5,013	0,722

Fonte: dados simulados (script do Apêndice A).

3.4 COMO ESCOLHER O MODELO NOS DADOS REAIS

- Explicar ou prever. Para explicar a interação G×E ou o efeito de uma covariável, modelos mistos, regressão fatorial, GAM e modelos penalizados entregam coeficientes ou curvas interpretáveis. Para prever em larga escala, vale o modelo de menor erro no teste entre os candidatos (BREIMAN, 2001b).
- Começar pelo simples. Com poucas centenas de observações e relações próximas do aditivo, regressão linear, penalizada ou GAM costumam bastar; métodos de aprendizado de máquina só justificam a complexidade se ganharem no teste, como mostrou o exemplo (HASTIE; TIBSHIRANI; FRIEDMAN, 2009).
- Respeitar a estrutura dos dados. Parcelas, voos e safras não são independentes; a validação deve separar blocos inteiros e, nos dados reais, ambientes e cultivares novos (ROBERTS et al., 2017).
- Sempre ter um modelo de referência e checar a calibração. O novo modelo precisa superar a média ou a regressão linear, e o gráfico de observado contra predito deve ser examinado junto com o R^2 (LIN, 1989; VAN CALSTER et al., 2019).
- Usar as duas camadas. A ambientômica explica o que causou a variação e a fenômica a mede; modelos que usam as duas, como o proposto nos Artigos 3 e 4 com covariáveis e índices RGB, tendem a ser mais úteis para a decisão (FRITSCHE-NETO et al., 2025).

REFERÊNCIAS BIBLIOGRÁFICAS

AKAIKE, H. A new look at the statistical model identification. IEEE Transactions on Automatic Control, v. 19, n. 6, p. 716-723, 1974. DOI: https://doi.org/10.1109/TAC.1974.1100705.

ALVES, A. K. S.; ARAÚJO, M. S.; CHAVES, S. F. S.; DIAS, L. A. S.; CORRÊDO, L. P.; PESSOA, G. G. F. A.; BEZERRA, A. R. G. High throughput phenotyping in soybean breeding using RGB image vegetation indices based on drone. Scientific Reports, v. 14, art. 32055, 2024. DOI: https://doi.org/10.1038/s41598-024-83807-4.

ARAÚJO, M. S.; PAVAN, J. P. S.; STELLA, A. A.; FREGONEZI, B. F.; LIMA, N. F.; LELES, E. P.; SANTOS, M. F.; GOLDSMITH, P.; CHIGEZA, G.; DIERS, B. W.; PINHEIRO, J. B. Optimizing soybean variety selection for the Pan-African Trial network using factor analytic models and envirotyping. Frontiers in Plant Science, v. 16, art. 1594736, 2025. DOI: https://doi.org/10.3389/fpls.2025.1594736.

ARAUS, J. L.; CAIRNS, J. E. Field high-throughput phenotyping: the new crop breeding frontier. Trends in Plant Science, v. 19, n. 1, p. 52-61, 2014. DOI: https://doi.org/10.1016/j.tplants.2013.09.008.

ARAUS, J. L.; KEFAUVER, S. C.; ZAMAN-ALLAH, M.; OLSEN, M. S.; CAIRNS, J. E. Translating high-throughput phenotyping into genetic gain. Trends in Plant Science, v. 23, n. 5, p. 451-466, 2018. DOI: https://doi.org/10.1016/j.tplants.2018.02.001.

BABESKI, C. M.; CARVALHO, I. R.; LUZ, G. B.; BRUGNEROTTO, P.; KRAHN, C. O.; LÚCIO, A. D. Fenômica e ambientômica como ferramenta no monitoramento e melhoria do ambiente. Capítulo de livro.

BAI, D.; LI, D.; ZHAO, C.; WANG, Z.; SHAO, M.; GUO, B.; LIU, Y.; WANG, Q.; LI, J.; GUO, S.; WANG, R.; LI, Y.; QIU, L.; JIN, X. Estimation of soybean yield parameters under lodging conditions using RGB information from unmanned aerial vehicles. Frontiers in Plant Science, v. 13, art. 1012293, 2022. DOI: https://doi.org/10.3389/fpls.2022.1012293.

BEALE, D. J. et al. Omics-based ecosurveillance for the assessment of ecosystem function, health, and resilience. Emerging Topics in Life Sciences, v. 6, n. 2, p. 185-199, 2022. DOI: https://doi.org/10.1042/ETLS20210261.

BOCK, C. H.; CHIANG, K.-S.; DEL PONTE, E. M. Plant disease severity estimated visually: a century of research, best practices, and opportunities for improving methods and practice to maximize accuracy. Tropical Plant Pathology, v. 47, p. 25-42, 2022. DOI: https://doi.org/10.1007/s40858-021-00439-z.

BOMBRUN, M. et al. Forest-scale phenotyping: productivity characterisation through machine learning. Frontiers in Plant Science, v. 11, art. 99, 2020. DOI: https://doi.org/10.3389/fpls.2020.00099.

BREIMAN, L. Random forests. Machine Learning, v. 45, n. 1, p. 5-32, 2001a. DOI: https://doi.org/10.1023/A:1010933404324.

BREIMAN, L. Statistical modeling: the two cultures. Statistical Science, v. 16, n. 3, p. 199-231, 2001b. DOI: https://doi.org/10.1214/ss/1009213726.

BURNHAM, K. P.; ANDERSON, D. R. Model selection and multimodel inference: a practical information-theoretic approach. 2. ed. New York: Springer, 2002. DOI: https://doi.org/10.1007/b97636.

CHAGAS, J. T. B.; ARAÚJO, M. S.; PAVAN, J. P. S.; FRANÇANI, A. O.; FERREIRA, G. N. C.; STELLA, A. A.; MARTINEZ, M.; RETORE, Y. I.; FREGONEZI, B. F.; MARTINS, G. M.; ZHAO, T.; ZHOU, J.; SOUSA, D. R.; GAO, Y.; JI, D.; GAO, K.; LI, B.; LIU, S.; ZHAO, L.; PINHEIRO, J. B. Harnessing high-throughput phenotyping and artificial intelligence for soybean breeding: from trait assessment to data-driven decisions. Plant Phenomics, art. 100259, 2026. DOI: https://doi.org/10.1016/j.plaphe.2026.100259.

CHAI, T.; DRAXLER, R. R. Root mean square error (RMSE) or mean absolute error (MAE)? Arguments against avoiding RMSE in the literature. Geoscientific Model Development, v. 7, n. 3, p. 1247-1250, 2014. DOI: https://doi.org/10.5194/gmd-7-1247-2014.

CHEN, T.; GUESTRIN, C. XGBoost: a scalable tree boosting system. In: ACM SIGKDD INTERNATIONAL CONFERENCE ON KNOWLEDGE DISCOVERY AND DATA MINING, 22., 2016, San Francisco. Proceedings [...]. New York: ACM, 2016. p. 785-794. DOI: https://doi.org/10.1145/2939672.2939785.

COELHO, J. S. P.; ALVES, R. S.; PEIXOTO, M. A.; RESENDE, M. D. V.; TEODORO, P. E.; SILVA, F. L.; BHERING, L. L. Produtividade, estabilidade e adaptabilidade da soja por meio de metodologia de modelo misto. Ciência Rural, v. 51, n. 2, art. e20200406, 2021. DOI: https://doi.org/10.1590/0103-8478cr20200406.

CORTES, C.; VAPNIK, V. Support-vector networks. Machine Learning, v. 20, n. 3, p. 273-297, 1995. DOI: https://doi.org/10.1007/BF00994018.

COSTA-NETO, G. M. F.; RESENDE, R. T.; FRITSCHE-NETO, R.; HEINEMANN, A. B. Ambientômica. In: RESENDE, R. T.; BRONDANI, C. (ed.). Melhoramento de precisão: aplicações e perspectivas na genética de plantas. Brasília, DF: Embrapa, 2023. cap. 8, p. 195-225.

COSTA-NETO, G.; FRITSCHE-NETO, R.; CROSSA, J. Nonlinear kernels, dominance, and envirotyping data increase the accuracy of genome-based prediction in multi-environment trials. Heredity, v. 126, n. 1, p. 92-106, 2021a. DOI: https://doi.org/10.1038/s41437-020-00353-1.

COSTA-NETO, G.; GALLI, G.; CARVALHO, H. F.; CROSSA, J.; FRITSCHE-NETO, R. EnvRtype: a software to interplay enviromics and quantitative genomics in agriculture. G3: Genes, Genomes, Genetics, v. 11, n. 4, art. jkab040, 2021b. DOI: https://doi.org/10.1093/g3journal/jkab040.

COVER, T.; HART, P. Nearest neighbor pattern classification. IEEE Transactions on Information Theory, v. 13, n. 1, p. 21-27, 1967. DOI: https://doi.org/10.1109/TIT.1967.1053964.

CRAIN, J.; MONDAL, S.; RUTKOSKI, J.; SINGH, R. P.; POLAND, J. Combining high-throughput phenotyping and genomic information to increase prediction and selection accuracy in wheat breeding. The Plant Genome, v. 11, n. 1, art. 170043, 2018. DOI: https://doi.org/10.3835/plantgenome2017.05.0043.

CRUZ, C. D.; REGAZZI, A. J.; CARNEIRO, P. C. S. Modelos biométricos aplicados ao melhoramento genético. 4. ed. Viçosa, MG: UFV, 2012. v. 1.

EBERHART, S. A.; RUSSELL, W. A. Stability parameters for comparing varieties. Crop Science, v. 6, n. 1, p. 36-40, 1966.

FALCONER, D. S.; MACKAY, T. F. C. Introduction to quantitative genetics. 4. ed. Harlow: Longman, 1996.

FINLAY, K. W.; WILKINSON, G. N. The analysis of adaptation in a plant-breeding programme. Australian Journal of Agricultural Research, v. 14, n. 6, p. 742-754, 1963. DOI: https://doi.org/10.1071/AR9630742.

FRIEDMAN, J. H. Greedy function approximation: a gradient boosting machine. The Annals of Statistics, v. 29, n. 5, p. 1189-1232, 2001. DOI: https://doi.org/10.1214/aos/1013203451.

FRITSCHE-NETO, R.; RESENDE, R. T.; OLIVOTO, T.; ABADILLO VELASCO, J. G.; NASCIMENTO, M.; BAHIA, M. A. M.; JARQUIN, D.; VIEIRA, R. A. Prediction-based breeding: modern tools to optimize and reshape programs. Crop Science, v. 65, n. 5, art. e70175, 2025. DOI: https://doi.org/10.1002/csc2.70175.

FURBANK, R. T.; TESTER, M. Phenomics: technologies to relieve the phenotyping bottleneck. Trends in Plant Science, v. 16, n. 12, p. 635-644, 2011. DOI: https://doi.org/10.1016/j.tplants.2011.09.005.

GAUCH, H. G. Statistical analysis of regional yield trials: AMMI analysis of factorial designs. Amsterdam: Elsevier, 1992.

GELMAN, A.; JAKULIN, A.; PITTAU, M. G.; SU, Y.-S. A weakly informative default prior distribution for logistic and other regression models. The Annals of Applied Statistics, v. 2, n. 4, p. 1360-1383, 2008. DOI: https://doi.org/10.1214/08-AOAS191.

HASTIE, T.; TIBSHIRANI, R. Generalized additive models. Statistical Science, v. 1, n. 3, p. 297-310, 1986. DOI: https://doi.org/10.1214/ss/1177013604.

HASTIE, T.; TIBSHIRANI, R.; FRIEDMAN, J. The elements of statistical learning: data mining, inference, and prediction. 2. ed. New York: Springer, 2009. DOI: https://doi.org/10.1007/978-0-387-84858-7.

HOERL, A. E.; KENNARD, R. W. Ridge regression: biased estimation for nonorthogonal problems. Technometrics, v. 12, n. 1, p. 55-67, 1970. DOI: https://doi.org/10.1080/00401706.1970.10488634.

HOULE, D.; GOVINDARAJU, D. R.; OMHOLT, S. Phenomics: the next challenge. Nature Reviews Genetics, v. 11, n. 12, p. 855-866, 2010. DOI: https://doi.org/10.1038/nrg2897.

HUBER, P. J. Robust estimation of a location parameter. The Annals of Mathematical Statistics, v. 35, n. 1, p. 73-101, 1964. DOI: https://doi.org/10.1214/aoms/1177703732.

HURVICH, C. M.; TSAI, C.-L. Regression and time series model selection in small samples. Biometrika, v. 76, n. 2, p. 297-307, 1989. DOI: https://doi.org/10.1093/biomet/76.2.297.

JAMES, G.; WITTEN, D.; HASTIE, T.; TIBSHIRANI, R. An introduction to statistical learning: with applications in R. 2. ed. New York: Springer, 2021. DOI: https://doi.org/10.1007/978-1-0716-1418-1.

JARQUÍN, D. et al. A reaction norm model for genomic selection using high-dimensional genomic and environmental data. Theoretical and Applied Genetics, v. 127, n. 3, p. 595-607, 2014. DOI: https://doi.org/10.1007/s00122-013-2243-1.

LECUN, Y.; BENGIO, Y.; HINTON, G. Deep learning. Nature, v. 521, n. 7553, p. 436-444, 2015. DOI: https://doi.org/10.1038/nature14539.

LIN, L. I.-K. A concordance correlation coefficient to evaluate reproducibility. Biometrics, v. 45, n. 1, p. 255-268, 1989. DOI: https://doi.org/10.2307/2532051.

MACHADO E SILVA, C.; MEZZOMO, H. C.; RIBEIRO, J. P. O.; SIGNORINI, V. S.; LIMA, G. W.; VIEIRA, E. F. T.; PORTES, M. F.; MOROTA, G.; CORREDO, L. P.; NARDINO, M. Insights on multi-spectral vegetation indices derived from UAV-based high-throughput phenotyping for indirect selection in tropical wheat breeding. Euphytica, v. 220, n. 3, art. 35, 2024. DOI: https://doi.org/10.1007/s10681-024-03299-1.

MANSOOR, S. et al. Genomics, phenomics, and machine learning in transforming plant research: advancements and challenges. Horticultural Plant Journal, v. 11, n. 2, p. 486-503, 2025. DOI: https://doi.org/10.1016/j.hpj.2023.09.005.

PINHEIRO, J. C.; BATES, D. M. Mixed-effects models in S and S-PLUS. New York: Springer, 2000. DOI: https://doi.org/10.1007/b98882.

RESENDE, R. T. et al. Enviromics in breeding: applications and perspectives on envirotypic-assisted selection. Theoretical and Applied Genetics, v. 134, p. 95-112, 2021. DOI: https://doi.org/10.1007/s00122-020-03684-z.

RESENDE, R. T.; XAVIER, A.; SILVA, P. I. T.; RESENDE, M. P. M.; JARQUIN, D.; MARCATTI, G. E. GIS-based G × E modeling of maize hybrids through enviromic markers engineering. New Phytologist, v. 245, n. 1, p. 102-116, 2025. DOI: https://doi.org/10.1111/nph.19951.

ROBERTS, D. R.; BAHN, V.; CIUTI, S.; BOYCE, M. S.; ELITH, J.; GUILLERA-ARROITA, G.; HAUENSTEIN, S.; LAHOZ-MONFORT, J. J.; SCHRÖDER, B.; THUILLER, W.; WARTON, D. I.; WINTLE, B. A.; HARTIG, F.; DORMANN, C. F. Cross-validation strategies for data with temporal, spatial, hierarchical, or phylogenetic structure. Ecography, v. 40, n. 8, p. 913-929, 2017. DOI: https://doi.org/10.1111/ecog.02881.

RUMELHART, D. E.; HINTON, G. E.; WILLIAMS, R. J. Learning representations by back-propagating errors. Nature, v. 323, n. 6088, p. 533-536, 1986. DOI: https://doi.org/10.1038/323533a0.

RUTKOSKI, J.; POLAND, J.; MONDAL, S.; AUTRIQUE, E.; PÉREZ, L. G.; CROSSA, J.; REYNOLDS, M.; SINGH, R. Canopy temperature and vegetation indices from high-throughput phenotyping improve accuracy of pedigree and genomic selection for grain yield in wheat. G3: Genes, Genomes, Genetics, v. 6, n. 9, p. 2799-2808, 2016. DOI: https://doi.org/10.1534/g3.116.032888.

SEBER, G. A. F.; WILD, C. J. Nonlinear regression. New York: Wiley, 1989. DOI: https://doi.org/10.1002/0471725315.

SOUSA, J. M. A.; BLASQUES, G. M.; CONDÉ, A. T.; SILVA, A. F.; EIDES, J. R.; FRONZA, R. T. L.; FERNANDES, S. B.; CARNEIRO, P. C. S.; BHERING, L. L.; NARDINO, M.; DIAS,

K. O. G. Modeling genotype-by-environment interaction for variety recommendation in tropical wheat. Crop Science, 2026. DOI: https://doi.org/10.1002/csc2.70309.

TIBSHIRANI, R. Regression shrinkage and selection via the lasso. Journal of the Royal Statistical Society: Series B, v. 58, n. 1, p. 267-288, 1996. DOI: https://doi.org/10.1111/j.2517-6161.1996.tb02080.x.

VAN CALSTER, B.; MCLERNON, D. J.; VAN SMEDEN, M.; WYNANTS, L.; STEYERBERG, E. W. Calibration: the Achilles heel of predictive analytics. BMC Medicine, v. 17, art. 230, 2019. DOI: https://doi.org/10.1186/s12916-019-1466-7.

VOLPATO, L.; ALVES, R. S.; TEODORO, P. E.; RESENDE, M. D. V.; NASCIMENTO, M.; NASCIMENTO, A. C. C.; LUDKE, W. H.; SILVA, F. L.; BORÉM, A.; LIGHTFOOT, D. A. Multi-trait multi-environment models in the genetic selection of segregating soybean progeny. PLOS ONE, v. 14, n. 4, art. e0215315, 2019. DOI: https://doi.org/10.1371/journal.pone.0215315.

WILLMOTT, C. J.; MATSUURA, K. Advantages of the mean absolute error (MAE) over the root mean square error (RMSE) in assessing average model performance. Climate Research, v. 30, n. 1, p. 79-82, 2005. DOI: https://doi.org/10.3354/cr030079.

WOOD, S. N. Generalized additive models: an introduction with R. 2. ed. Boca Raton: CRC Press, 2017. DOI: https://doi.org/10.1201/9781315370279.

XU, Y. Envirotyping for deciphering environmental impacts on crop plants. Theoretical and Applied Genetics, v. 129, n. 4, p. 653-673, 2016. DOI: https://doi.org/10.1007/s00122-016-2691-5.

ZAVAFER, A.; BATES, H.; MANCILLA, C.; RALPH, P. J. Phenomics: conceptualization and importance for plant physiology. Trends in Plant Science, v. 28, n. 9, p. 1004-1013, 2023. DOI: https://doi.org/10.1016/j.tplants.2023.03.023.

APÊNDICE A - SCRIPT EM R (QUESTÃO 3)

Script completo, com as citações nos comentários. Os arquivos acompanham este documento: script_questao3_ivan.R, Questao3_Ivan_Ambientomica_Fenomica.Rmd (relatório R Markdown) e Questao3_Ivan_Ambientomica_Fenomica.html (relatório renderizado).

```
# QUESTÃO 3 (Prof. Ivan Ricardo Carvalho): modelos para ambientômica e fenômica
# Cristhian Milbradt Babeski, PPGA/UFSM. Versão simples e comentada, com as citações dentro do código.
# O que faz: simula um banco (ambiente + imagem RGB + severidade), divide 80/20 e compara 15 modelos (mais XGBoost e
# deep learning se `xgboost` e `keras` estiverem instalados). Roda inteiro em cerca de 15 segundos.
# Como usar: abra no RStudio e rode linha por linha, ou source("script_questao3_ivan.R", encoding = "UTF-8").
# Saídas: dados_questao3_ivan.xlsx (banco) e resultado_modelos_questao3_ivan.xlsx (tabela de desempenho).
# O relatório R Markdown correspondente é Questao3_Ivan_Ambientomica_Fenomica.Rmd (mesmo código, com texto e figuras).


# ======== PACOTES ========
# Todos os pacotes abaixo são instalados com install.packages("nome").
pacotes <- c("glmnet", "mgcv", "e1071", "ranger", "gbm", "MASS", "nnet", "nlme", "arm", "caret", "openxlsx", "ggplot2")
for (p in pacotes) library(p, character.only = TRUE)
set.seed(123)   # semente única: o resultado se repete em qualquer computador


# Métricas no teste. RMSE pune mais os erros grandes; MAE é o erro médio absoluto (CHAI; DRAXLER, 2014; WILLMOTT; MATSUURA, 2005).
metricas <- function(obs, pred) c(RMSE = sqrt(mean((obs - pred)^2)),
                                  MAE  = mean(abs(obs - pred)),
                                  R2   = 1 - sum((obs - pred)^2) / sum((obs - mean(obs))^2))
resultados <- list()                                              # guarda uma linha por modelo
guarda <- function(nome, familia, pred) resultados[[nome]] <<- data.frame(Modelo = nome, Familia = familia, t(metricas(teste$sev, as.numeric(pred))))




# ======== DADOS ========
n <- 600                                                  # ordem de grandeza dos ensaios da tese (250 a 1000 pontos)


# --- Camada ambientômica: covariáveis do tipo NASA POWER (XU, 2016; RESENDE et al., 2021) ---
temp   <- rnorm(n, 24, 3)                                 # temperatura média (°C)
umid   <- pmin(pmax(rnorm(n, 75, 10), 40), 100)           # umidade relativa (%)
precip <- rgamma(n, shape = 2, scale = 15)                # precipitação (mm)
rad    <- rnorm(n, 18, 3)                                 # radiação (MJ/m2/dia)


# --- Severidade: umidade e chuva favorecem a doença; a temperatura tem um ótimo (resposta quadrática) ---
fav <- 0.6 * scale(umid) + 0.4 * scale(precip) - 0.03 * (temp - 24)^2
sev <- pmin(pmax(30 + 12 * as.numeric(fav) + rnorm(n, 0, 5), 0), 100)


# --- Camada fenômica: a doença reduz o verde e aumenta o vermelho; o azul é quase só ruído ---
R <- 90  + 0.5 * sev + rnorm(n, 0, 8)
G <- 130 - 0.6 * sev + 0.3 * rad + rnorm(n, 0, 8)
B <- 60  + rnorm(n, 0, 10)


# Índices de vegetação RGB (fórmulas usadas nos artigos 3 e 4 da tese). O ExGR fica de fora aqui: é combinação linear exata de R, G e B e deixaria a matriz singular.
VARI  <- (G - R) / (G + R - B)
GLI   <- (2 * G - R - B) / (2 * G + R + B)
NGRDI <- (G - R) / (G + R)


dados <- data.frame(sev, temp, umid, precip, rad, R, G, B, VARI, GLI, NGRDI)
write.xlsx(dados, "dados_questao3_ivan.xlsx")             # o banco fica salvo em Excel
head(round(dados, 3))




# ======== SPLIT ========
i_teste <- sample(n, 0.2 * n)
treino  <- dados[-i_teste, ]; teste <- dados[i_teste, ]
```

```
# Padronizar usando só o treino evita vazamento de informação para o teste (HASTIE; TIBSHIRANI; FRIEDMAN,
2009).
preditoras <- setdiff(names(dados), "sev")
centro <- sapply(treino[preditoras], mean); escala <- sapply(treino[preditoras], sd)
padroniza <- function(d) as.data.frame(scale(d[preditoras], center = centro, scale = escala))
Xtr <- padroniza(treino); Xte <- padroniza(teste)
tr <- cbind(sev = treino$sev, Xtr); te <- cbind(sev = teste$sev, Xte)    # versões padronizadas
f_todas <- reformulate(preditoras, "sev")
c(treino = nrow(treino), teste = nrow(teste))




# ======== LINEARES ========
# 1. Regressão linear múltipla (mínimos quadrados): Y = b0 + soma(bi Xi) (JAMES et al., 2021).
m_lm <- lm(f_todas, tr);                          guarda("Regressão linear (Lm)", "Linear", predict(m_lm,
te))


# 2. Stepwise: tira ou coloca variáveis pelo AIC (AKAIKE, 1974).
m_step <- step(m_lm, trace = 0);                  guarda("Stepwise (AIC)", "Linear", predict(m_step, te))


# 3. Regressão com interação entre bandas: R, G, B e produtos entre elas (modelo do projeto, sem citação
específica).
m_int <- lm(sev ~ (R + G + B)^3 + temp + umid + precip + rad, tr)
guarda("Regressão com interação R x G x B", "Linear", predict(m_int, te))


# 4. Mínimos quadrados generalizados: aceita variância do erro que cresce com a média (PINHEIRO; BATES,
2000).
m_gls <- gls(f_todas, data = tr, weights = varPower(form = ~ fitted(.)))
guarda("GLS (variância heterogênea)", "Linear", predict(m_gls, te))




# ======== ROBUSTO ========
# 5. Regressão robusta: M-estimador de Huber, pesa menos os outliers (HUBER, 1964; VENABLES; RIPLEY, 2002).
m_rlm <- rlm(f_todas, tr, psi = psi.huber);       guarda("Regressão robusta (rlm, Huber)", "Robusto/Bayes",
predict(m_rlm, te))


# 6. Regressão bayesiana: prior fraco (Cauchy) sobre os coeficientes (GELMAN et al., 2008).
m_bayes <- bayesglm(f_todas, data = tr, family = gaussian)
guarda("Regressão bayesiana (bayesglm)", "Robusto/Bayes", predict(m_bayes, te))




# ======== PENALIZADOS ========
xtr <- as.matrix(Xtr); xte <- as.matrix(Xte)
# 7. Ridge: penalidade L2, encolhe coeficientes de preditoras correlacionadas (HOERL; KENNARD, 1970).
cv_r <- cv.glmnet(xtr, tr$sev, alpha = 0)         # lambda escolhido por validação cruzada (FRIEDMAN;
HASTIE; TIBSHIRANI, 2010)
guarda("Ridge", "Penalizado", predict(cv_r, xte, s = "lambda.min"))


# 8. Lasso: penalidade L1, zera coeficientes e seleciona variáveis (TIBSHIRANI, 1996).
cv_l <- cv.glmnet(xtr, tr$sev, alpha = 1)
guarda("Lasso", "Penalizado", predict(cv_l, xte, s = "lambda.min"))
coef(cv_l, s = "lambda.min")                       # quais variáveis o Lasso manteve




# ======== NAOLINEARES ========
# 9. GAM: soma de curvas suaves (splines), uma por variável (HASTIE; TIBSHIRANI, 1986; WOOD, 2017).
m_gam <- gam(sev ~ s(temp) + s(umid) + s(precip) + s(rad) + s(R) + s(G) + s(B) + s(VARI) + s(GLI) +
s(NGRDI), data = tr, method = "REML")
guarda("GAM", "Não linear", predict(m_gam, te))


# 10. Regressão não linear (nLnn): forma paramétrica com ótimo térmico, sev = b0 + b1 umid + b2 precip + b3
(temp - topt)^2 + b4 VARI (SEBER; WILD, 1989).
m_nl <- nls(sev ~ b0 + b1 * umid + b2 * precip + b3 * (temp - topt)^2 + b4 * VARI, data = treino,
            start = list(b0 = 30, b1 = 0.5, b2 = 0.1, b3 = -0.3, topt = 24, b4 = -50))
guarda("Regressão não linear (nls)", "Não linear", predict(m_nl, teste))




# ======== ML ========
```

```
# 11. KNN: média da resposta dos k vizinhos mais próximos (COVER; HART, 1967). k = 7 fixo, por
simplicidade.
guarda("KNN (k = 7)", "ML", predict(knnreg(xtr, tr$sev, k = 7), xte))


# 12. SVM com kernel radial: hiperplano de margem máxima (CORTES; VAPNIK, 1995); custo e gamma por
validação cruzada.
ajuste_svm <- tune.svm(f_todas, data = tr, cost = 2^(0:4), gamma = 2^(-6:-2))
guarda("SVM (radial)", "ML", predict(ajuste_svm$best.model, te))


# 13. Random Forest: média de 500 árvores sorteadas com reposição (BREIMAN, 2001a; WRIGHT; ZIEGLER, 2017).
m_rf <- ranger(f_todas, data = treino, num.trees = 500, importance = "permutation", seed = 123)
guarda("Random Forest", "ML", predict(m_rf, teste)$predictions)
sort(m_rf$variable.importance, decreasing = TRUE)   # importância por permutação




# ======== BOOSTING ========
# 14. Gradient Boosting (GBM): árvores pequenas somadas, cada uma corrigindo o erro das anteriores
(FRIEDMAN, 2001).
m_gbm <- gbm(f_todas, data = treino, distribution = "gaussian", n.trees = 500, shrinkage = 0.05,
             interaction.depth = 2, cv.folds = 5, verbose = FALSE)
guarda("Gradient Boosting (GBM)", "ML", predict(m_gbm, teste, n.trees = gbm.perf(m_gbm, method = "cv",
plot.it = FALSE)))


# 15. XGBoost: boosting com regularização das árvores (CHEN; GUESTRIN, 2016). Só roda se o pacote estiver
instalado.
if (requireNamespace("xgboost", quietly = TRUE)) {
  m_xgb <- xgboost::xgboost(data = xtr, label = tr$sev, nrounds = 200, max_depth = 3, eta = 0.05, verbose =
0)
  guarda("XGBoost", "ML", predict(m_xgb, xte))
} else message("xgboost não instalado: rode install.packages('xgboost') para incluir este modelo.")


# 16. Rede neural artificial rasa: uma camada oculta com 5 neurônios (RUMELHART; HINTON; WILLIAMS, 1986).
m_rna <- nnet(f_todas, data = tr, size = 5, decay = 0.1, linout = TRUE, maxit = 500, trace = FALSE)
guarda("Rede neural (1 camada)", "ML", predict(m_rna, te))


# Aprendizado profundo (várias camadas ocultas; LECUN; BENGIO; HINTON, 2015): exige keras/TensorFlow, por
isso fica opcional.
if (requireNamespace("keras", quietly = TRUE)) {
  library(keras)
  m_dl <- keras_model_sequential() |> layer_dense(64, "relu", input_shape = ncol(xtr)) |> layer_dense(32,
"relu") |> layer_dense(1)
  m_dl |> compile(loss = "mse", optimizer = "adam")
  m_dl |> fit(xtr, tr$sev, epochs = 150, batch_size = 32, validation_split = 0.2, verbose = 0)
  guarda("Deep learning (3 camadas)", "ML", predict(m_dl, xte))
} else message("keras não instalado: o bloco de deep learning foi pulado.")




# ======== TABELA ========
tabela <- do.call(rbind, resultados); rownames(tabela) <- NULL
tabela <- tabela[order(-tabela$R2), ]
tabela[, c("RMSE", "MAE", "R2")] <- round(tabela[, c("RMSE", "MAE", "R2")], 3)
tabela
write.xlsx(tabela, "resultado_modelos_questao3_ivan.xlsx")
melhor <- tabela[which.max(tabela$R2), ]; pior <- tabela[which.min(tabela$R2), ]   # para o texto abaixo




# ======== GRAFICO ========
tabela$Modelo <- factor(tabela$Modelo, levels = rev(tabela$Modelo))
ggplot(tabela, aes(Modelo, R2, fill = Familia)) + geom_col() + coord_flip() +
  labs(title = "R² no teste (20%)", x = NULL, y = "R²") + theme_minimal(base_size = 12)




# ======== BLOCOS ========
amb <- c("temp", "umid", "precip", "rad"); fen <- c("R", "G", "B", "VARI", "GLI", "NGRDI")
roda <- function(vars, modelo) {
  f <- reformulate(vars, "sev")
  p <- if (modelo == "Linear (Lm)") predict(lm(f, treino), teste) else predict(ranger(f, treino, num.trees
= 500, seed = 123), teste)$predictions
  round(metricas(teste$sev, p), 3)
}
```

```
blocos <- expand.grid(Preditoras = c("Só ambiente", "Só imagem RGB", "Ambiente + imagem"), Modelo =
c("Linear (Lm)", "Random Forest"))
conj <- list("Só ambiente" = amb, "Só imagem RGB" = fen, "Ambiente + imagem" = c(amb, fen))
blocos <- cbind(blocos, t(mapply(function(p, m) roda(conj[[as.character(p)]], as.character(m)),
blocos$Preditoras, blocos$Modelo)))
blocos


# ======== REFERÊNCIAS CITADAS NOS COMENTÁRIOS ========
# AKAIKE, H. A new look at the statistical model identification. IEEE Transactions on Automatic Control, v.
19, n. 6, p. 716-723, 1974.
# BREIMAN, L. Random forests. Machine Learning, v. 45, n. 1, p. 5-32, 2001a.
# BREIMAN, L. Statistical modeling: the two cultures. Statistical Science, v. 16, n. 3, p. 199-231, 2001b.
# CHAI, T.; DRAXLER, R. R. Root mean square error (RMSE) or mean absolute error (MAE)? Geoscientific Model
Development, v. 7, n. 3, p. 1247-1250, 2014.
# CHEN, T.; GUESTRIN, C. XGBoost: a scalable tree boosting system. KDD, 22., 2016. p. 785-794.
# CORTES, C.; VAPNIK, V. Support-vector networks. Machine Learning, v. 20, n. 3, p. 273-297, 1995.
# COVER, T.; HART, P. Nearest neighbor pattern classification. IEEE Transactions on Information Theory, v.
13, n. 1, p. 21-27, 1967.
# FRIEDMAN, J. H. Greedy function approximation: a gradient boosting machine. The Annals of Statistics, v.
29, n. 5, p. 1189-1232, 2001.
# FRIEDMAN, J.; HASTIE, T.; TIBSHIRANI, R. Regularization paths for generalized linear models via
coordinate descent. Journal of Statistical Software, v. 33, n. 1, p. 1-22, 2010.
# GELMAN, A.; JAKULIN, A.; PITTAU, M. G.; SU, Y.-S. A weakly informative default prior distribution for
logistic and other regression models. The Annals of Applied Statistics, v. 2, n. 4, p. 1360-1383, 2008.
# HASTIE, T.; TIBSHIRANI, R. Generalized additive models. Statistical Science, v. 1, n. 3, p. 297-310,
1986.
# HASTIE, T.; TIBSHIRANI, R.; FRIEDMAN, J. The elements of statistical learning. 2. ed. New York: Springer,
2009.
# HOERL, A. E.; KENNARD, R. W. Ridge regression: biased estimation for nonorthogonal problems.
Technometrics, v. 12, n. 1, p. 55-67, 1970.
# HUBER, P. J. Robust estimation of a location parameter. The Annals of Mathematical Statistics, v. 35, n.
1, p. 73-101, 1964.
# JAMES, G.; WITTEN, D.; HASTIE, T.; TIBSHIRANI, R. An introduction to statistical learning: with
applications in R. 2. ed. New York: Springer, 2021.
# LECUN, Y.; BENGIO, Y.; HINTON, G. Deep learning. Nature, v. 521, p. 436-444, 2015.
# PINHEIRO, J. C.; BATES, D. M. Mixed-effects models in S and S-PLUS. New York: Springer, 2000.
# RESENDE, R. T. et al. Enviromics in breeding: applications and perspectives on envirotypic-assisted
selection. Theoretical and Applied Genetics, v. 134, p. 95-112, 2021.
# ROBERTS, D. R. et al. Cross-validation strategies for data with temporal, spatial, hierarchical, or
phylogenetic structure. Ecography, v. 40, n. 8, p. 913-929, 2017.
# RUMELHART, D. E.; HINTON, G. E.; WILLIAMS, R. J. Learning representations by back-propagating errors.
Nature, v. 323, p. 533-536, 1986.
# SEBER, G. A. F.; WILD, C. J. Nonlinear regression. New York: Wiley, 1989.
# TIBSHIRANI, R. Regression shrinkage and selection via the lasso. Journal of the Royal Statistical Society
B, v. 58, n. 1, p. 267-288, 1996.
# VENABLES, W. N.; RIPLEY, B. D. Modern applied statistics with S. 4. ed. New York: Springer, 2002.
# WILLMOTT, C. J.; MATSUURA, K. Advantages of the mean absolute error (MAE) over the root mean square error
(RMSE) in assessing average model performance. Climate Research, v. 30, n. 1, p. 79-82, 2005.
# WOOD, S. N. Generalized additive models: an introduction with R. 2. ed. Boca Raton: CRC Press, 2017.
# WRIGHT, M. N.; ZIEGLER, A. ranger: a fast implementation of random forests for high dimensional data in
C++ and R. Journal of Statistical Software, v. 77, n. 1, p. 1-17, 2017.
# XU, Y. Envirotyping for deciphering environmental impacts on crop plants. Theoretical and Applied
Genetics, v. 129, p. 653-673, 2016.
```